Ajuste de curvas y regresión

Material de teoría

Índice

1. Introducción 2
2. Ajuste, interpolación y predicción 2
3. El modelo de regresión lineal 2
4. Datos, predicciones y residuos 3
5. Método de mínimos cuadrados 3
6. Cálculo de la pendiente e intercepto 4
7. Ejemplo de regresión lineal 4
8. Regresión polinomial 4
9. Regresión no lineal 4
   9.1. Modelo exponencial . . . 5
   9.2. Modelo potencial . . . 5
   9.3. Modelo logístico . . . 5
10. Ajuste de modelos físicos 5
11. Calidad del ajuste 5
12. Análisis de residuos 6
13. Sobreajuste 6
14. Regresión y modelos físicos: una estrategia general 6
15. Ideas clave 7

1. Introducción

En muchos problemas científicos, de ingeniería y empresariales tenemos un conjunto de datos experimentales y queremos encontrar una función matemática que describa su comportamiento.

Por ejemplo, podemos medir la distancia recorrida por un objeto en diferentes instantes:

Tiempo t (s)	Distancia d (m)
0	0.2
1	2.1
2	4.0
3	6.2
4	8.1
5	10.3

Los puntos no tienen por qué encontrarse exactamente sobre una función. Las mediciones contienen ruido, errores de instrumento y variaciones propias del fenómeno.

El objetivo del **ajuste de curvas** es encontrar una función que represente razonablemente bien los datos.

2. Ajuste, interpolación y predicción

Es importante distinguir tres ideas:

- **Interpolación:** encontrar valores entre observaciones conocidas.
- **Ajuste:** encontrar un modelo que represente globalmente los datos, permitiendo errores.
- **Predicción:** utilizar el modelo para estimar valores que no fueron observados.

En un problema experimental normalmente no buscamos una curva que pase exactamente por todos los puntos. Buscamos una curva que capture el comportamiento general.

3. El modelo de regresión lineal

El modelo lineal simple tiene la forma

$$\hat{y} = b_0 + b_1 x.$$

Aquí:

- x es la variable independiente;
- y es la variable observada;
- $\hat{y}$ es el valor estimado por el modelo;
- b_0 es el intercepto;
- b_1 es la pendiente.

La pendiente indica cuánto cambia, en promedio, y cuando x aumenta una unidad.

El intercepto corresponde al valor estimado de y cuando $x = 0$.

4. Datos, predicciones y residuos

Supongamos que tenemos observaciones (x_i, y_i).
El modelo produce una predicción:

$$\hat{y}_i = b_0 + b_1 x_i.$$

La diferencia entre el valor observado y el valor predicho se denomina **residuo**:

$$e_i = y_i - \hat{y}_i.$$

El residuo puede ser positivo o negativo.

La siguiente figura permite visualizar los cuatro elementos fundamentales del ajuste: los datos observados, la recta ajustada, las predicciones y los residuos.

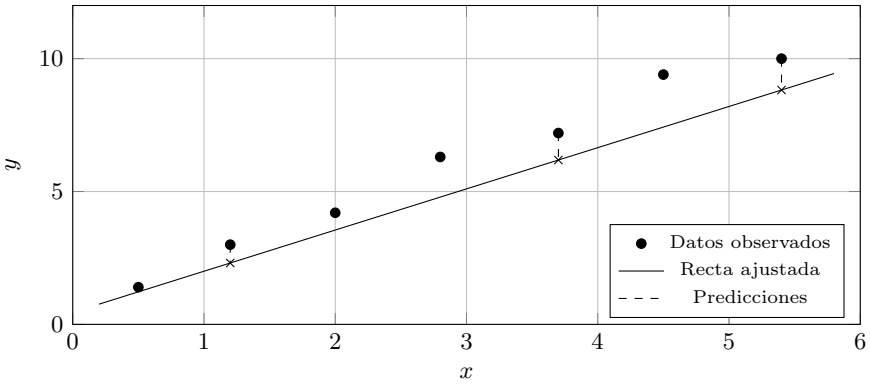


Figura 1: Datos observados, recta de ajuste, predicciones y residuos. Las líneas verticales punteadas representan los residuos.

En la Figura 1, cada punto representa una observación experimental. La recta representa el modelo ajustado y las marcas de predicción muestran el valor que el modelo asigna a determinados valores de x.

La distancia vertical entre una observación y su predicción representa el residuo:

$$e_i = y_i - \hat{y}_i.$$

Por tanto, podemos pensar el proceso de ajuste como una secuencia:

$$\boxed{\text{Datos} \longrightarrow \text{Modelo} \longrightarrow \text{Predicciones} \longrightarrow \text{Residuos}}$$

5. Método de mínimos cuadrados

Si tenemos n observaciones, podemos medir el error total mediante la suma de los cuadrados de los residuos:

$$S = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

Para una regresión lineal:

$$S = \sum_{i=1}^{n} \left[y_i - (b_0 + b_1 x_i) \right]^2.$$

El método de mínimos cuadrados busca los valores de b_0 y b_1 que minimizan S.

Elevar al cuadrado tiene varias ventajas:

- evita que errores positivos y negativos se cancelen;
- penaliza más los errores grandes;
- permite formular un problema matemático de optimización.

6. Cálculo de la pendiente e intercepto

Para regresión lineal simple:

$$b_1 = \frac{n\sum x_i y_i - (\sum x_i)(\sum y_i)}{n\sum x_i^2 - (\sum x_i)^2}.$$

Y:

$$b_0 = \bar{y} - b_1\bar{x}.$$

Por tanto, una vez calculados estos dos parámetros, tenemos el modelo completo:

$$\boxed{\hat{y} = b_0 + b_1 x}.$$

7. Ejemplo de regresión lineal

Consideremos:

$$x = [1, 2, 3, 4, 5]$$

y

$$y = [2{,}1, 4{,}0, 6{,}2, 8{,}1, 10{,}3].$$

Al realizar el ajuste obtenemos aproximadamente:

$$\hat{y} \approx 0{,}02 + 2{,}04x.$$

El modelo permite estimar, por ejemplo, el valor correspondiente a $x = 6$:

$$\hat{y}(6) \approx 0{,}02 + 2{,}04(6) = 12{,}26.$$

La estimación no debe confundirse con una medición real.

8. Regresión polinomial

No todos los datos siguen una recta. Un modelo polinomial de grado 2 tiene la forma

$$\hat{y} = a_2x^2 + a_1x + a_0.$$

Un polinomio de grado 3 tiene la forma

$$\hat{y} = a_3x^3 + a_2x^2 + a_1x + a_0.$$

El ajuste polinomial también puede realizarse mediante mínimos cuadrados.
En Python, NumPy proporciona:

```
np.polyfit(x, y, grado)
```

Por ejemplo:

```
coeficientes = np.polyfit(x, y, 2)
```

ajusta un polinomio cuadrático.

9. Regresión no lineal

Un modelo puede no ser lineal respecto a sus parámetros. Algunos ejemplos son:

9.1. Modelo exponencial

$$y = Ae^{kx}.$$

9.2. Modelo potencial

$$y = Ax^n.$$

9.3. Modelo logístico

$$y = \frac{L}{1 + e^{-k(x-x_0)}}.$$

En estos casos podemos utilizar algoritmos numéricos para encontrar los parámetros que minimizan el error.
En Python, una herramienta habitual es:

```
scipy.optimize.curve_fit
```

10. Ajuste de modelos físicos

Una aplicación especialmente importante es utilizar datos experimentales para estimar parámetros de un modelo físico.

Para movimiento uniformemente acelerado:

$$d(t) = d_0 + v_0 t + \frac{1}{2}at^2.$$

Esta ecuación puede escribirse como

$$d(t) = \left(\frac{a}{2}\right) t^2 + v_0 t + d_0.$$

Por tanto, si ajustamos un polinomio de grado 2:

$$d(t) = At^2 + Bt + C,$$

podemos interpretar los coeficientes físicamente:

$$a = 2A, \qquad v_0 = B, \qquad d_0 = C.$$

Este es un ejemplo fundamental de análisis de datos: el algoritmo produce parámetros matemáticos y nosotros les damos significado físico.

11. Calidad del ajuste

Un modelo no se evalúa solamente mirando la curva.

Podemos calcular el error cuadrático medio:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2.$$

También podemos utilizar la raíz del error cuadrático medio:

$$RMSE = \sqrt{MSE}.$$

El RMSE tiene las mismas unidades que y, por lo que suele ser fácil de interpretar.

Otra medida común en regresión lineal es el coeficiente de determinación:

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}.$$

Un valor cercano a 1 indica que el modelo explica una gran parte de la variabilidad observada, aunque **un R^2 alto no garantiza que el modelo sea físicamente correcto**.

12. Análisis de residuos

Los residuos son una herramienta esencial para evaluar el modelo.
Un buen ajuste suele producir residuos:

- relativamente pequeños;
- distribuidos alrededor de cero;
- sin patrones evidentes.

Si los residuos presentan una estructura clara, puede indicar que el modelo elegido no representa adecuadamente los datos.

Por ejemplo, si utilizamos una recta para describir datos con comportamiento curvo, los residuos pueden formar un patrón en forma de arco.

13. Sobreajuste

Un modelo demasiado sencillo puede no capturar el comportamiento de los datos.
Pero un modelo demasiado complejo puede aprender incluso el ruido experimental.
Este fenómeno se denomina **sobreajuste**.
Por ejemplo, un polinomio de grado muy alto puede pasar prácticamente por todos los puntos, pero producir predicciones poco confiables fuera de las observaciones.
Por esta razón:

Un buen modelo no es necesariamente el modelo más complejo.

14. Regresión y modelos físicos: una estrategia general

Ante un conjunto de datos experimentales podemos seguir este procedimiento:

1. Identificar las variables.
2. Graficar los datos.
3. Proponer uno o varios modelos.
4. Ajustar los parámetros.
5. Calcular las predicciones.
6. Analizar los residuos.
7. Calcular métricas de error.
8. Interpretar los parámetros.
9. Evaluar si el modelo tiene sentido físico o contextual.
10. Utilizar el modelo para realizar predicciones.

15. Ideas clave

- Ajustar una curva significa encontrar un modelo que represente datos observados.
- Los residuos miden la diferencia entre observación y predicción.
- Mínimos cuadrados minimiza la suma de los residuos al cuadrado.
- La regresión lineal utiliza un modelo de la forma $b_0 + b_1 x$.
- Los modelos polinomiales permiten representar relaciones curvas.
- La regresión no lineal permite ajustar modelos más generales.
- Un modelo físico permite interpretar los parámetros obtenidos.
- La gráfica y el análisis de residuos son tan importantes como el valor de una métrica.
- Un modelo debe evaluarse por su capacidad de representar el fenómeno, no solamente por su error numérico.