Ajuste de curvas y regresión

Mínimos cuadrados, regresión y ajuste de modelos físicos

Computación Avanzada y Analítica

Objetivos de la sesión

- Comprender qué significa ajustar un modelo a datos experimentales.
- Diferenciar ajuste, interpolación y predicción.
- Interpretar datos observados, predicciones y residuos.
- Comprender el método de mínimos cuadrados.
- Aplicar regresión lineal.
- Implementar una regresión lineal en Python.
- Evaluar la calidad de un ajuste.

Motivación: datos experimentales

Supongamos que un experimento produce:

$t\,(s)$	0	1	2	3	4	5
$d\,(m)$	0,2	2,1	4,0	6,2	8,1	10,3

Motivación: datos experimentales

Supongamos que un experimento produce:

$t\,(s)$	0	1	2	3	4	5
$d\,(m)$	0,2	2,1	4,0	6,2	8,1	10,3

Los datos no tienen por qué encontrarse exactamente sobre una recta.

Pregunta

¿Qué ecuación podría representar el comportamiento general de estos datos?

Ajuste, interpolación y predicción

Interpolación

Estimar valores que se encuentran entre observaciones conocidas.

Ajuste

Encontrar un modelo que represente globalmente los datos permitiendo errores.

Predicción

Utilizar el modelo para estimar valores que no fueron observados.

El modelo de regresión lineal

El modelo lineal simple es:

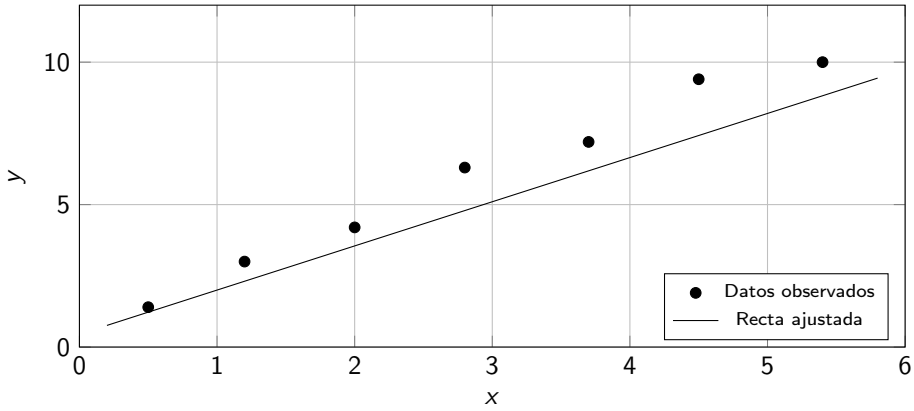
$$\boxed{\hat{y} = b_0 + b_1 x}$$

- b_0: intercepto.
- b_1: pendiente.
- x: variable independiente.
- y: valor observado.
- $\hat{y}$: valor predicho.

Pregunta

¿Cómo elegimos b_0 y b_1?

Datos y recta ajustada



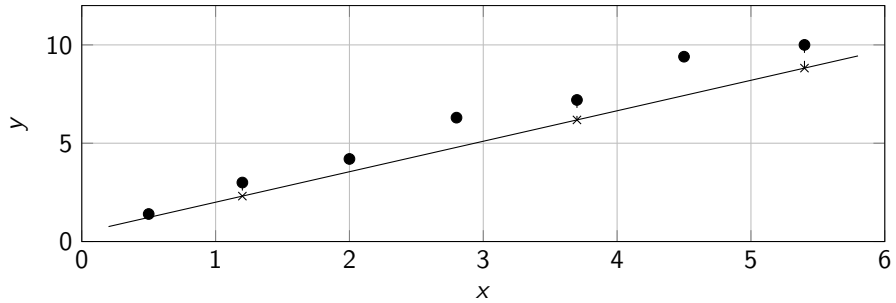
Predicciones y residuos

Para cada observación:

$$\hat{y}_i = b_0 + b_1 x_i$$

El residuo es:

$$e_i = y_i - \hat{y}_i$$



Idea clave

La idea de mínimos cuadrados

Queremos que los residuos sean pequeños.
Si simplemente sumamos:

$$\sum e_i$$

los errores positivos y negativos pueden cancelarse.
Por eso utilizamos:

$$\boxed{S = \sum_{i=1}^{n} e_i^2}$$

Objetivo

Encontrar el modelo que minimiza la suma de los cuadrados de los residuos.

Mínimos cuadrados para una recta

Para:

$$\hat{y} = b_0 + b_1 x$$

$$S = \sum_{i=1}^{n} [y_i - (b_0 + b_1 x_i)]^2$$

El método busca los valores de b_0 y b_1 que minimizan S.

¿Por qué elevar los residuos al cuadrado?

- Evita la cancelación entre errores positivos y negativos.
- Hace que los errores grandes tengan mayor peso.
- Permite formular un problema de optimización.

Pregunta para la clase

Si un punto tiene un residuo dos veces mayor que otro, ¿qué ocurre con su contribución a S?

Fórmulas de la regresión lineal

$$b_1 = \frac{n\sum x_i y_i - (\sum x_i)(\sum y_i)}{n\sum x_i^2 - (\sum x_i)^2}$$

$$b_0 = \bar{y} - b_1 \bar{x}$$

Fórmulas de la regresión lineal

$$b_1 = \frac{n\sum x_i y_i - (\sum x_i)(\sum y_i)}{n\sum x_i^2 - (\sum x_i)^2}$$

$$b_0 = \bar{y} - b_1 \bar{x}$$

$$\boxed{\hat{y} = b_0 + b_1 x}$$

Ejemplo: cálculo manual

Consideremos:

$$x = [1, 2, 3, 4, 5]$$

$$y = [2{,}1, 4{,}0, 6{,}2, 8{,}1, 10{,}3]$$

Actividad

Calcular:

1. $\sum x$
2. $\sum y$
3. $\sum xy$
4. $\sum x^2$
5. b_0
6. b_1

Resultado del ajuste

Para los datos anteriores obtenemos aproximadamente:

$$\boxed{\hat{y} \approx 0{,}02 + 2{,}04x}$$

Si $x = 6$:

$$\hat{y}(6) \approx 0{,}02 + 2{,}04(6) = 12{,}26$$

Importante

Una predicción no es una medición real.

Regresión lineal en Python

```
import numpy as np

x = np.array([1, 2, 3, 4, 5])
y = np.array([2.1, 4.0, 6.2, 8.1, 10.3])

n = len(x)

b1 = (n*np.sum(x*y) - np.sum(x)*np.sum(y)) / \\
     (n*np.sum(x**2) - np.sum(x)**2)

b0 = np.mean(y) - b1*np.mean(x)

print("Pendiente:", b1)
print("Intercepto:", b0)
```

Predicciones y residuos en Python

```
y_pred = b0 + b1*x
residuos = y - y_pred

for xi, yi, yp, e in zip(x, y, y_pred, residuos):
    print(xi, yi, yp, e)
```

Conexión

El código reproduce el proceso:

$$\text{datos} \rightarrow \text{predicciones} \rightarrow \text{residuos}$$

Calidad del ajuste

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

$$\boxed{RMSE = \sqrt{MSE}}$$

El RMSE tiene las mismas unidades que la variable y.

Coeficiente de determinación

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

Advertencia

Un R^2 alto no garantiza que el modelo sea físicamente correcto.

Análisis de residuos

Un buen ajuste suele producir residuos:

- relativamente pequeños;
- distribuidos alrededor de cero;
- sin patrones evidentes.

Pregunta

¿Qué podría significar que los residuos formen una curva?

Probablemente el modelo lineal no está capturando completamente el comportamiento de los datos.

¿Qué hacemos cuando los datos no siguen una recta?

Podemos utilizar otros modelos:

$$y = ax^2 + bx + c$$

$$y = Ae^{kx}$$

$$y = Ax^n$$

Regresión polinomial

Un polinomio de grado 2:

$$\hat{y} = a_2 x^2 + a_1 x + a_0$$

En Python:

```
coef = np.polyfit(x, y, 2)
modelo = np.poly1d(coef)
```

Pregunta

¿Por qué no utilizar siempre un polinomio de grado muy alto?

Ejemplo: ajuste polinomial

Consideremos:

x	0	1	2	3	4	5
y	1,1	2,0	5,2	9,1	17,2	25,1

Actividad

1. Graficar los datos.
2. Ajustar un polinomio de grado 2.
3. Generar predicciones.
4. Comparar visualmente el modelo con los datos.

Sobreajuste

Un modelo demasiado complejo puede aprender incluso el ruido experimental.
Por ejemplo, un polinomio de grado muy alto puede pasar por casi todos los puntos.

Idea clave

$$\boxed{\text{Buen ajuste} \neq \text{máxima complejidad}}$$

Debemos buscar un equilibrio entre error, interpretación y capacidad de generalización.

Regresión no lineal

Algunos modelos no son lineales respecto a sus parámetros.
Por ejemplo:

$$\boxed{y = Ae^{kx}}$$

$$\boxed{y = Ax^n}$$

En estos casos podemos utilizar algoritmos numéricos para encontrar los parámetros que minimizan el error.

Modelo exponencial en Python

```
from scipy.optimize import curve_fit

def modelo(x, A, k):
    return A * np.exp(k*x)

parametros, covarianza = curve_fit(
    modelo, x, y
)

A, k = parametros
```

La idea sigue siendo la misma

$$\text{Datos} \rightarrow \text{Modelo} \rightarrow \text{Predicciones} \rightarrow \text{Residuos} \rightarrow \text{Minimizar error}$$

Idea clave

Lo que cambia es la forma del modelo y el procedimiento utilizado para encontrar sus parámetros.

Ajuste de modelos físicos

Para movimiento uniformemente acelerado:

$$\boxed{d(t) = d_0 + v_0 t + \frac{1}{2} a t^2}$$

Podemos escribir:

$$d(t) = At^2 + Bt + C$$

donde:

$$a = 2A, \qquad v_0 = B, \qquad d_0 = C.$$

Ejemplo físico

Supongamos que medimos:

$t(s)$	0	0,2	0,4	0,6	0,8	1,0
$d(m)$	0,03	0,19	0,82	1,76	3,13	4,92

Pregunta

¿Qué modelo físico esperamos que describa estos datos?

Ejemplo físico

Supongamos que medimos:

$t(s)$	0	0,2	0,4	0,6	0,8	1,0
$d(m)$	0,03	0,19	0,82	1,76	3,13	4,92

Pregunta

¿Qué modelo físico esperamos que describa estos datos?

$$d(t) = d_0 + v_0 t + \frac{1}{2} a t^2$$

Ajustando el modelo físico

```
coef = np.polyfit(t, d, 2)

A, B, C = coef

a = 2*A
v0 = B
d0 = C

print("d0 =", d0)
print("v0 =", v0)
print("a =", a)
```

Interpretación de los parámetros

Si:

$$d(t) = At^2 + Bt + C,$$

entonces:

$$\boxed{a = 2A}$$

$$\boxed{v_0 = B}$$

$$\boxed{d_0 = C}$$

Idea fundamental

El algoritmo produce parámetros matemáticos; el análisis del fenómeno les da significado físico.

Residuos del modelo físico

Después del ajuste calculamos:

$$e_i = d_i - \hat{d}_i.$$

- ¿Son pequeños?
- ¿Están alrededor de cero?
- ¿Presentan algún patrón?
- ¿El modelo físico parece adecuado?

Estrategia general

Ante un conjunto de datos experimentales:

1. Identificar las variables.
2. Graficar los datos.
3. Proponer uno o varios modelos.
4. Ajustar los parámetros.
5. Calcular predicciones.
6. Analizar residuos.
7. Calcular métricas de error.
8. Interpretar los parámetros.
9. Evaluar si el modelo tiene sentido físico.
10. Realizar predicciones.

Actividad final

A partir de un conjunto de datos experimentales:

1. Graficar los datos.
2. Proponer un modelo.
3. Ajustar sus parámetros.
4. Generar predicciones.
5. Calcular residuos.
6. Calcular RMSE.
7. Graficar datos y modelo.
8. Graficar residuos.
9. Interpretar los parámetros.
10. Realizar una predicción.

Problema de cierre

Una empresa registra el crecimiento de una población durante varias horas.

Reto

Determinar qué modelo representa mejor los datos y justificar la elección.

1. ¿Lineal?
2. ¿Polinomial?
3. ¿Exponencial?
4. ¿Otro modelo?

Pregunta de cierre

¿Por qué eligieron ese modelo y no otro?

Conclusiones

- Ajustar significa encontrar un modelo que represente los datos.
- Los residuos miden la diferencia entre observación y predicción.
- Mínimos cuadrados minimiza la suma de los residuos al cuadrado.
- La regresión lineal permite ajustar relaciones aproximadamente lineales.
- Los modelos polinomiales permiten representar relaciones curvas.
- La regresión no lineal permite utilizar modelos más generales.
- Los modelos físicos permiten interpretar los parámetros obtenidos.
- Un buen modelo no es necesariamente el modelo más complejo.

Idea central

Los datos se convierten en modelos matemáticos que podemos interpretar y utilizar para predecir.