UNIVERSIDAD EIA

Computación Avanzada y Analítica

Optimización numérica

Optimización numérica: métodos unidimensionales, gradiente y aplicaciones físicas

Material de teoría

Índice

1. Objetivos 3

2. ¿Qué significa optimizar? 3

3. Formulación de un problema de optimización 3

4. Mínimos y máximos 4
- 4.1. Mínimo global . . . 4
- 4.2. Mínimo local . . . 4
- 4.3. Idea clave . . . 4

5. Optimización unidimensional 4

6. Búsqueda exhaustiva 4
- 6.1. Interpretación computacional . . . 4

7. Unimodalidad 4

8. Método de la sección áurea 5
- 8.1. Criterio de parada . . . 5
- 8.2. Ventaja computacional . . . 5

9. Algoritmo de la sección áurea 5

10. Ejemplo de optimización unidimensional 5

11. Aplicación física: energía potencial 6

12. De una dimensión a muchas dimensiones 6

13. Derivadas parciales 6

14. El gradiente 6

15. Interpretación geométrica del gradiente 7

16. Descenso por gradiente 7

17. El tamaño de paso α **7**

18. Criterios de parada **7**

19. Ejemplo bidimensional **8**

20. Gradiente numérico mediante diferencias finitas **8**
20.1. Elección de h 8

21. Aplicación física bidimensional: mínima energía **8**

22. Optimización y dinámica física **8**

23. Superficies con múltiples mínimos **9**

24. Visualización de la optimización **9**

25. Comparación de métodos **9**

26. Buenas prácticas computacionales **9**

27. Errores frecuentes **10**

28. Resumen de algoritmos **10**
28.1. Búsqueda exhaustiva 10
28.2. Sección áurea 10
28.3. Descenso por gradiente 10
28.4. Gradiente numérico 10

29. Ejercicios propuestos **10**

30. Preguntas de reflexión **11**

31. Idea central para recordar **11**

1. Objetivos

- Comprender qué significa formular un problema como una optimización.
- Diferenciar mínimos y máximos locales de los globales.
- Aplicar estrategias de búsqueda para optimización unidimensional.
- Comprender e implementar el método de la sección áurea.
- Interpretar el gradiente como dirección de máximo crecimiento.
- Implementar descenso por gradiente en varias variables.
- Analizar el efecto del punto inicial, el tamaño de paso y el criterio de parada.
- Aplicar optimización numérica a problemas con interpretación física.

2. ¿Qué significa optimizar?

Optimizar significa buscar la mejor solución posible de acuerdo con un criterio. En matemáticas, ingeniería, ciencias y analítica esto suele traducirse en minimizar un costo, error o energía, o maximizar un beneficio, rendimiento o producción.

Un problema general de minimización puede escribirse como

$$\boxed{\min_{x \in D} f(x)}.$$

De manera análoga, un problema de maximización es

$$\boxed{\max_{x \in D} f(x)}.$$

Aquí x representa las variables de decisión, f es la función objetivo y D representa el conjunto de valores permitidos.

3. Formulación de un problema de optimización

Una formulación completa debe identificar:

1. las variables que podemos modificar;
2. la función objetivo que queremos minimizar o maximizar;
3. el dominio o conjunto de valores admisibles;
4. las restricciones adicionales del problema.

Por ejemplo, considere

$$C(x) = \frac{100}{x} + 2x^2, \qquad 1 \leq x \leq 10.$$

El problema consiste en encontrar el valor de x que produzca el menor costo dentro del intervalo permitido:

$$\min_{1 \leq x \leq 10} C(x).$$

No basta con conocer la función: también debemos saber qué valores de x son físicamente o computacionalmente válidos.

4. Mínimos y máximos

4.1. Mínimo global

Un punto x^* es un mínimo global de f sobre D si

$$f(x^*) \leq f(x) \qquad \text{para todo } x \in D.$$

Es decir, ningún otro punto permitido produce un valor menor.

4.2. Mínimo local

Un punto x^* es un mínimo local si $f(x^*)$ es menor o igual que los valores de f en una vecindad de x^*. Puede existir otro punto, alejado de x^*, con un valor todavía menor.

De forma análoga se definen los máximos locales y globales.

4.3. Idea clave

Un algoritmo numérico puede encontrar un mínimo local sin garantizar que sea el mínimo global. Esta diferencia será especialmente importante en problemas multidimensionales con varios valles.

5. Optimización unidimensional

En optimización unidimensional existe una sola variable:

$$\min_{a \leq x \leq b} f(x).$$

Geométricamente buscamos el punto más bajo de la gráfica de f dentro del intervalo.

Una estrategia sencilla consiste en evaluar la función en muchos puntos y escoger el mejor.

6. Búsqueda exhaustiva

Dividimos $[a, b]$ en una malla de n puntos:

$$x_i = a + i\frac{b-a}{n-1}, \qquad i = 0, 1, \ldots, n-1.$$

Calculamos $f(x_i)$ y elegimos

$$x^* = \arg\min_i f(x_i).$$

La ventaja principal es su simplicidad. La desventaja es que puede requerir muchas evaluaciones y solo encuentra el mejor punto de la malla, no necesariamente el mínimo exacto.

6.1. Interpretación computacional

La búsqueda exhaustiva es útil como punto de partida porque permite visualizar el problema y comprobar resultados de métodos más sofisticados. También muestra una idea fundamental: la optimización numérica requiere un equilibrio entre precisión y costo computacional.

7. Unimodalidad

Una función es unimodal en un intervalo si tiene un único mínimo en ese intervalo y, aproximadamente, decrece hasta ese mínimo y crece después de él.

Esta propiedad es importante porque permite descartar regiones del intervalo sin evaluar todos sus puntos. El método de la sección áurea aprovecha precisamente esta idea.

No todas las funciones son unimodales en un intervalo dado. Por ejemplo, una función con varios valles puede tener varios mínimos locales y no cumplir esta condición.

8. Método de la sección áurea

La sección áurea es un método de búsqueda para minimizar funciones unimodales en un intervalo.
Se define la razón

$$r = \frac{\sqrt{5}-1}{2} \approx 0{,}618.$$

Para un intervalo actual $[a, b]$, se consideran los puntos

$$x_1 = b - r(b-a), \qquad x_2 = a + r(b-a).$$

Se evalúa la función en estos puntos. Si

$$f(x_1) < f(x_2),$$

el mínimo se busca en $[a, x_2]$. Si

$$f(x_1) > f(x_2),$$

el mínimo se busca en $[x_1, b]$.

El intervalo se reduce progresivamente hasta alcanzar una tolerancia.

8.1. Criterio de parada

Un criterio sencillo es

$$\boxed{|b-a| < \varepsilon}.$$

Cuando el intervalo es suficientemente pequeño, podemos tomar como aproximación

$$x^* \approx \frac{a+b}{2}.$$

8.2. Ventaja computacional

Una característica importante es que, después de la primera etapa, una de las evaluaciones de la función puede reutilizarse en la siguiente iteración. Por ello la sección áurea reduce el número de evaluaciones frente a una búsqueda exhaustiva con una malla muy fina.

9. Algoritmo de la sección áurea

El procedimiento puede resumirse así:

1. Elegir $[a, b]$, una tolerancia ε y un máximo de iteraciones.
2. Calcular x_1 y x_2 usando la razón áurea.
3. Evaluar $f(x_1)$ y $f(x_2)$.
4. Eliminar la región que no puede contener el mínimo.
5. Reutilizar la evaluación que permanece dentro del nuevo intervalo.
6. Repetir hasta que $|b-a| < \varepsilon$ o se alcance el máximo de iteraciones.

10. Ejemplo de optimización unidimensional

Considere nuevamente

$$C(x) = \frac{100}{x} + 2x^2, \qquad 1 \le x \le 10.$$

Queremos resolver

$$\min_{1 \le x \le 10} C(x).$$

Con una búsqueda exhaustiva podemos obtener una primera aproximación. Posteriormente, si la función es unimodal en el intervalo de interés, la sección áurea permite refinar la solución.

El objetivo pedagógico no es solamente obtener un número, sino comparar dos estrategias: una que explora directamente una malla y otra que descarta regiones sucesivamente.

11. Aplicación física: energía potencial

Una aplicación natural de la optimización es la búsqueda de estados de mínima energía.

Considere la energía potencial unidimensional

$$U(x) = x^4 - 4x^2 + 3.$$

Sus derivadas permiten observar que existen varios puntos críticos, pero los métodos numéricos permiten localizar mínimos sin depender necesariamente de una solución simbólica.

La presencia de más de un mínimo permite introducir una idea importante: cuando existen varios valles, encontrar "un" mínimo no implica necesariamente encontrar el mínimo global.

12. De una dimensión a muchas dimensiones

En varias variables escribimos

$$\mathbf{x} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix}^T$$

y buscamos

$$\boxed{\min_{\mathbf{x} \in D} f(\mathbf{x})}.$$

Para dos variables, $f(x, y)$ puede interpretarse como una superficie. Otra representación útil son las curvas de nivel: cada curva reúne puntos que tienen el mismo valor de la función.

13. Derivadas parciales

Para una función $f(x, y)$, las derivadas parciales son

$$\frac{\partial f}{\partial x}, \qquad \frac{\partial f}{\partial y}.$$

La derivada parcial respecto de una variable mide cómo cambia la función cuando modificamos esa variable manteniendo las demás constantes.

Para n variables, cada componente del gradiente corresponde a una derivada parcial.

14. El gradiente

El gradiente de una función $f(x, y)$ es

$$\boxed{\nabla f(x, y) = \begin{bmatrix} \dfrac{\partial f}{\partial x} \\ \dfrac{\partial f}{\partial y} \end{bmatrix}}$$

y para n variables:

$$\boxed{\nabla f(\mathbf{x}) = \begin{bmatrix} \dfrac{\partial f}{\partial x_1} \\ \dfrac{\partial f}{\partial x_2} \\ \vdots \\ \dfrac{\partial f}{\partial x_n} \end{bmatrix}}.$$

15. Interpretación geométrica del gradiente

El gradiente apunta en la dirección de máximo crecimiento de la función. Por tanto, la dirección de máximo descenso es

$$\boxed{-\nabla f(\mathbf{x})}.$$

Para un vector unitario $\mathbf{u}$, la derivada direccional es

$$D_{\mathbf{u}} f(\mathbf{x}) = \nabla f(\mathbf{x}) \cdot \mathbf{u}.$$

Por la desigualdad de Cauchy–Schwarz,

$$\nabla f \cdot \mathbf{u} \leq \|\nabla f\|,$$

y el máximo se alcanza cuando $\mathbf{u}$ apunta en la dirección del gradiente.

Por esta razón, para minimizar una función nos interesa movernos en dirección opuesta al gradiente.

16. Descenso por gradiente

El descenso por gradiente actualiza la solución mediante

$$\boxed{\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \nabla f(\mathbf{x}_k)}.$$

Aquí $\alpha > 0$ es el tamaño de paso.

El algoritmo básico es:

1. Elegir un punto inicial $\mathbf{x}_0$.
2. Calcular $\nabla f(\mathbf{x}_k)$.
3. Actualizar $\mathbf{x}_{k+1}$.
4. Verificar el criterio de parada.
5. Repetir hasta converger o alcanzar el máximo de iteraciones.

17. El tamaño de paso α

El parámetro α controla cuánto avanzamos en cada iteración.

Si α es demasiado pequeño, el algoritmo puede avanzar muy lentamente. Si es demasiado grande, puede oscilar, alejarse del mínimo o incluso divergir.

Por ello, el valor de α no es un detalle secundario: forma parte fundamental del comportamiento del algoritmo.

18. Criterios de parada

Se pueden utilizar diferentes criterios. Uno de ellos compara dos iteraciones consecutivas:

$$\boxed{\|\mathbf{x}_{k+1} - \mathbf{x}_k\| < \varepsilon}.$$

Otro verifica que el gradiente sea suficientemente pequeño:

$$\boxed{\|\nabla f(\mathbf{x}_k)\| < \varepsilon}.$$

También debe establecerse un máximo de iteraciones para evitar ciclos infinitos o ejecuciones excesivamente largas.

19. Ejemplo bidimensional

Considere

$$f(x, y) = x^2 + y^2.$$

Su gradiente es

$$\nabla f(x, y) = \begin{bmatrix} 2x \\ 2y \end{bmatrix}.$$

El descenso por gradiente queda

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} x_k \\ y_k \end{bmatrix} - \alpha \begin{bmatrix} 2x_k \\ 2y_k \end{bmatrix}.$$

El mínimo global es $(0, 0)$.

Este ejemplo es especialmente útil porque permite visualizar la trayectoria de las iteraciones sobre las curvas de nivel.

20. Gradiente numérico mediante diferencias finitas

En algunas aplicaciones no conocemos las derivadas analíticas. Sin embargo, podemos aproximarlas numéricamente.

Para la componente i del gradiente, la diferencia central es

$$\boxed{\frac{\partial f}{\partial x_i}(\mathbf{x}) \approx \frac{f(\mathbf{x} + h\mathbf{e}_i) - f(\mathbf{x} - h\mathbf{e}_i)}{2h}}$$

con h suficientemente pequeño y $\mathbf{e}_i$ el vector unitario correspondiente.

Esto conecta los contenidos de diferenciación numérica con la optimización: podemos construir un gradiente aproximado y utilizarlo dentro del descenso por gradiente.

20.1. Elección de h

Un valor de h demasiado grande puede producir una aproximación poco precisa. Un valor excesivamente pequeño también puede ser problemático debido a errores de redondeo. En consecuencia, h debe elegirse considerando la escala del problema y la precisión numérica disponible.

21. Aplicación física bidimensional: mínima energía

Considere el potencial

$$\boxed{U(x, y) = \frac{1}{4}(x^2 - 1)^2 + \frac{1}{2}y^2}.$$

Su gradiente es

$$\boxed{\nabla U(x, y) = \begin{bmatrix} x(x^2 - 1) \\ y \end{bmatrix}}.$$

Los puntos $(1, 0)$ y $(-1, 0)$ son configuraciones de mínima energía.

El descenso por gradiente puede utilizarse para buscar una de estas configuraciones. Si comenzamos desde $(2, 1)$, la trayectoria tiende hacia $(1, 0)$; desde $(-2, 1)$, tiende hacia $(-1, 0)$.

La condición inicial es, por tanto, importante cuando existen múltiples mínimos locales.

22. Optimización y dinámica física

Cuando una función representa energía potencial, minimizarla puede tener una interpretación física como búsqueda de una configuración de baja energía.

Sin embargo, el descenso por gradiente no debe confundirse con una simulación temporal exacta de una partícula. El algoritmo es un procedimiento matemático de optimización. Su trayectoria representa una sucesión de decisiones computacionales que reducen la función objetivo.

23. Superficies con múltiples mínimos

Considere la función

$$E(x, y) = (x^2 + y^2 - 1)^2 + 0{,}2x^2.$$

Esta función puede utilizarse para estudiar cómo cambian las trayectorias de descenso según el punto inicial y el tamaño de paso.

Una actividad natural consiste en:

1. calcular el gradiente;
2. implementar descenso por gradiente;
3. probar diferentes puntos iniciales;
4. comparar distintos valores de α;
5. representar curvas de nivel y trayectorias.

24. Visualización de la optimización

La visualización ayuda a interpretar el algoritmo. En una dimensión podemos representar $f(x)$ y marcar la aproximación al mínimo. En dos dimensiones podemos representar curvas de nivel y dibujar sobre ellas la secuencia

$$\mathbf{x}_0, \mathbf{x}_1, \mathbf{x}_2, \ldots.$$

La trayectoria permite observar si el algoritmo avanza hacia el mínimo, si oscila, si converge lentamente o si se aleja debido a un tamaño de paso inadecuado.

25. Comparación de métodos

Método	Información principal	Ventaja	Limitación
Búsqueda exhaustiva	Valores de f	Simple	Muchas evaluaciones
Sección áurea	Valores de f	Reduce el intervalo eficientemente	Requiere unimodalidad
Descenso por gradiente	Gradiente	Escala a muchas variables	Depende de α
Gradiente numérico	Valores de f	No requiere derivadas analíticas	Más evaluaciones

No existe un método universalmente mejor. La elección depende de la dimensión, la disponibilidad de derivadas, la estructura de la función, las restricciones y el costo de evaluar la función.

26. Buenas prácticas computacionales

- Validar los parámetros de entrada, como intervalos, tolerancias y número máximo de iteraciones.
- Separar la función objetivo del algoritmo de optimización.
- Guardar el historial de iteraciones cuando se quiera analizar o visualizar la convergencia.
- Establecer criterios de parada claros.
- Comparar la solución obtenida con una solución conocida cuando sea posible.
- Probar diferentes condiciones iniciales en problemas con posibles múltiples mínimos.
- Registrar el número de evaluaciones de la función cuando se compare el costo computacional.

27. Errores frecuentes

- Confundir minimización con maximización.
- Confundir un mínimo local con el mínimo global.
- Aplicar sección áurea sin verificar las condiciones que justifican su uso.
- Elegir una tolerancia sin considerar la escala del problema.
- Usar un α excesivamente grande en descenso por gradiente.
- Usar un número máximo de iteraciones demasiado pequeño.
- Confundir el gradiente con la dirección de descenso: el gradiente apunta hacia el mayor crecimiento.
- Elegir un paso h inadecuado al calcular derivadas numéricas.
- Suponer que una trayectoria de descenso por gradiente representa necesariamente una trayectoria física real.

28. Resumen de algoritmos

28.1. Búsqueda exhaustiva

$$x_i = a + i\frac{b-a}{n-1}, \qquad x^* = \arg\min_i f(x_i).$$

28.2. Sección áurea

$$r = \frac{\sqrt{5}-1}{2}, \qquad x_1 = b - r(b-a), \qquad x_2 = a + r(b-a).$$

Se reduce el intervalo hasta que

$$|b-a| < \varepsilon.$$

28.3. Descenso por gradiente

$$\boxed{\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \nabla f(\mathbf{x}_k)}.$$

28.4. Gradiente numérico

$$\boxed{\frac{\partial f}{\partial x_i}(\mathbf{x}) \approx \frac{f(\mathbf{x}+h\mathbf{e}_i) - f(\mathbf{x}-h\mathbf{e}_i)}{2h}}.$$

29. Ejercicios propuestos

1. Implemente una búsqueda exhaustiva para minimizar $f(x) = (x-3)^2 + 2$ en $[0, 8]$. Estudie qué ocurre al cambiar el número de puntos de la malla.
2. Implemente la sección áurea para la misma función y compare el resultado con la búsqueda exhaustiva.
3. Para $f(x) = x^4 - 4x^2 + 3$, experimente con diferentes intervalos y analice la presencia de múltiples mínimos.
4. Implemente descenso por gradiente para $f(x, y) = x^2 + 2y^2$ y pruebe diferentes puntos iniciales.
5. Compare $\alpha = 0{,}01$, $0{,}1$ y $0{,}5$. Registre el número de iteraciones necesarias para cumplir una tolerancia fija.

6. Implemente el gradiente mediante diferencias finitas centrales y compárelo con el gradiente analítico.
7. Para $U(x, y) = \frac{1}{4}(x^2 - 1)^2 + \frac{1}{2}y^2$, pruebe al menos cuatro puntos iniciales y represente las trayectorias.
8. Para $E(x, y) = (x^2 + y^2 - 1)^2 + 0{,}2x^2$, obtenga el gradiente e investigue cómo influyen el punto inicial y α en la solución encontrada.

30. Preguntas de reflexión

1. ¿Por qué una búsqueda exhaustiva puede ser poco eficiente?
2. ¿Qué información permite reutilizar la sección áurea entre iteraciones?
3. ¿Por qué el gradiente negativo es una dirección de descenso?
4. ¿Qué puede ocurrir si α es demasiado grande?
5. ¿Por qué el punto inicial puede cambiar el mínimo encontrado?
6. ¿Qué ventajas y costos tiene calcular el gradiente mediante diferencias finitas?
7. ¿Por qué minimizar una energía potencial y simular la dinámica de una partícula no son exactamente el mismo problema?

31. Idea central para recordar

La optimización numérica busca transformar la pregunta

"¿cuál es la mejor solución?"

en un procedimiento computacional reproducible.

En una dimensión podemos explorar y reducir intervalos. En varias dimensiones podemos utilizar información de las derivadas mediante el gradiente. La idea fundamental del descenso por gradiente es

moverse en dirección opuesta al gradiente para reducir la función objetivo.

El éxito de un método depende no solo de la fórmula utilizada, sino también de las condiciones del problema, el punto inicial, la tolerancia, el tamaño de paso y el costo de las evaluaciones.