Optimización numérica

Optimización unidimensional, multidimensional y descenso por gradiente

Computación Avanzada y Analítica

Ruta de las dos sesiones

1. Optimización unidimensional
   - formulación
   - máximos y mínimos
   - búsqueda exhaustiva
   - sección áurea
2. Optimización multidimensional
   - derivadas parciales
   - gradiente
   - descenso por gradiente
   - aplicaciones físicas

Pregunta inicial: ¿qué significa optimizar?

Problema

Encontrar el valor de x que minimiza

$$C(x) = \frac{100}{x} + 2x^2, \qquad 1 \leq x \leq 10.$$

Pregunta para el grupo: ¿cómo lo resolverían sin derivar la función?

Formulación de un problema de optimización

$$\boxed{\min_{x \in D} f(x)} \quad \text{o} \quad \boxed{\max_{x \in D} f(x)}$$

- Variables de decisión.
- Función objetivo.
- Dominio y restricciones.

Mínimo local vs. mínimo global

Mínimo global

$f(x^*) \leq f(x)$ para todo x del dominio.

Mínimo local

$f(x^*)$ es menor o igual que los valores de una vecindad de x^*.

Mínimo local vs. mínimo global

Mínimo global

$f(x^*) \leq f(x)$ para todo x del dominio.

Mínimo local

$f(x^*)$ es menor o igual que los valores de una vecindad de x^*.

Idea clave: un algoritmo puede encontrar un mínimo local sin garantizar el mínimo global.

Optimización unidimensional

$$\min_{a \leq x \leq b} f(x)$$

- La búsqueda ocurre sobre un intervalo.
- Podemos evaluar muchos candidatos.
- Podemos reducir progresivamente la región de búsqueda.

Búsqueda exhaustiva

$$x_i = a + i\Delta x$$
$$i^* = \text{argmin}_i\, f(x_i)$$

- Muy sencilla.
- No necesita derivadas.
- Su precisión depende de la malla.
- Puede requerir muchas evaluaciones.

Búsqueda exhaustiva en Python

```
import numpy as np

x = np.linspace(0, 6, 1000)
y = (x - 3)**2 + 2

indice = np.argmin(y)
print(x[indice], y[indice])
```

Sección áurea

Para una función unimodal:

$$r = \frac{\sqrt{5}-1}{2} \approx 0.618$$

$$x_1 = b - r(b-a), \qquad x_2 = a + r(b-a)$$

Comparamos $f(x_1)$ y $f(x_2)$ y eliminamos una región.

Algoritmo de sección áurea

1. Definir $[a, b]$.
2. Calcular dos puntos interiores.
3. Evaluar la función.
4. Conservar el subintervalo prometedor.
5. Repetir.
6. Detener cuando $|b - a| < \varepsilon$.

Implementación: idea

```
def golden_section(f, a, b, tol=1e-6):
    r = (5**0.5 - 1) / 2
    x1 = b - r*(b-a)
    x2 = a + r*(b-a)
    f1, f2 = f(x1), f(x2)
    while abs(b-a) > tol:
        if f1 < f2:
            b, x2, f2 = x2, x1, f1
            x1 = b - r*(b-a)
            f1 = f(x1)
        else:
            a, x1, f1 = x1, x2, f2
            x2 = a + r*(b-a)
            f2 = f(x2)
    return (a+b)/2
```

Aplicación física: energía potencial

Si $U(x)$ representa energía potencial,

$$\boxed{\min_x U(x)}$$

puede representar un estado de equilibrio estable.

$$U(x) = x^4 - 4x^2 + 3$$

Puente a la segunda sesión

¿Qué cambia si tenemos dos variables?

$$f(x, y)$$

¿Y si tenemos n variables?

$$f(\mathrm{x})$$

Derivadas parciales y gradiente

$$\nabla f(x, y) = \begin{bmatrix} \partial f/\partial x \\ \partial f/\partial y \end{bmatrix}$$

Derivadas parciales y gradiente

$$\nabla f(x, y) = \begin{bmatrix} \partial f/\partial x \\ \partial f/\partial y \end{bmatrix}$$

Interpretación

El gradiente apunta hacia la dirección de máximo crecimiento.

Máximo descenso $\longrightarrow$ $-\nabla f$

Descenso por gradiente

$$\boxed{\mathsf{x}_{k+1} = \mathsf{x}_k - \alpha \nabla f(\mathsf{x}_k)}$$

- x_k: posición actual.
- ∇f: dirección de crecimiento.
- $-\nabla f$: dirección de descenso.
- α: tamaño del paso.

Ejemplo: $f(x, y) = x^2 + y^2$

$$\nabla f(x, y) = \begin{bmatrix} 2x \\ 2y \end{bmatrix}$$

Desde $(4, 3)$ con $\alpha = 0.1$:

$$(4, 3) \to (3.2, 2.4) \to (2.56, 1.92) \to \cdots$$

Mínimo

$(0, 0)$

El tamaño del paso importa

- α pequeño $\rightarrow$ convergencia lenta.
- α adecuado $\rightarrow$ convergencia eficiente.
- α grande $\rightarrow$ oscilaciones o divergencia.

El tamaño del paso importa

- α pequeño $\rightarrow$ convergencia lenta.
- α adecuado $\rightarrow$ convergencia eficiente.
- α grande $\rightarrow$ oscilaciones o divergencia.

No existe un único valor de α que funcione igual para todos los problemas.

Gradiente numérico

Cuando no conocemos las derivadas analíticas:

$$\frac{\partial f}{\partial x_i}(\mathrm{x}) \approx \frac{f(\mathrm{x} + h\mathrm{e}_i) - f(\mathrm{x} - h\mathrm{e}_i)}{2h}$$

Conexión

Diferenciación numérica $\rightarrow$ gradiente $\rightarrow$ optimización.

Aplicación física bidimensional

$$U(x,y) = \frac{1}{4}(x^2-1)^2 + \frac{1}{2}y^2$$

$$\nabla U = \begin{bmatrix} x(x^2-1) \\ y \end{bmatrix}$$

Pregunta

¿Qué ocurre si comenzamos en $(2,1)$? ¿Y en $(-2,1)$? ¿Y cerca del origen?

Interpretación física

- El algoritmo busca disminuir U.
- Cada iteración representa un desplazamiento en el espacio de estados.
- Los mínimos corresponden a configuraciones de menor energía.
- La condición inicial puede determinar qué mínimo local se alcanza.

Actividad de clase

Para la función

$$E(x, y) = (x^2 + y^2 - 1)^2 + 0.2x^2$$

1. Obtener el gradiente.
2. Implementar descenso por gradiente.
3. Probar cuatro puntos iniciales.
4. Comparar $\alpha = 0.01, 0.1, 0.5$.
5. Graficar curvas de nivel y trayectorias.

Buenas prácticas

1. Verificar la función objetivo.
2. Verificar el gradiente.
3. Registrar las iteraciones.
4. Probar distintos puntos iniciales.
5. Probar distintos tamaños de paso.
6. Establecer tolerancia y máximo de iteraciones.
7. Visualizar cuando sea posible.

Resumen

$$\boxed{\text{Problema} \rightarrow \text{modelo} \rightarrow \text{objetivo} \rightarrow \text{algoritmo} \rightarrow \text{convergencia}}$$

- Sección áurea: búsqueda eficiente en una dimensión.
- Gradiente: dirección de máximo crecimiento.
- Descenso por gradiente: movimiento hacia valores menores.
- Aplicaciones: diseño, energía, análisis y aprendizaje automático.

Preguntas finales

¿Un algoritmo que converge siempre encontró el mínimo global?

¿De qué depende la velocidad de convergencia?

¿Qué información aporta el gradiente?