Métodos Monte Carlo

Material de teoría

Índice

1. Objetivos de aprendizaje **2**

2. ¿Qué es un método Monte Carlo? **2**
2.1. Idea general . . . 2

3. Números aleatorios y muestreo **2**
3.1. Números verdaderamente aleatorios y pseudoaleatorios . . . 2
3.2. Distribuciones comunes . . . 3

4. Fundamento estadístico **3**

5. Integración Monte Carlo **3**
5.1. Derivación para una dimensión . . . 3
5.2. Estimación de la incertidumbre . . . 4
5.3. Ejemplo: integral de e^{-x^2} . . . 4
5.4. Estimación de π por área . . . 4
5.5. Integración en varias dimensiones . . . 5

6. Simulación estocástica **5**
6.1. Experimento de Bernoulli . . . 5
6.2. Buenas prácticas . . . 6

7. Caminatas aleatorias **6**
7.1. Caminata unidimensional simétrica . . . 6
7.2. Caminata aleatoria en dos dimensiones . . . 7
7.3. Conexión con difusión . . . 7

8. Limitaciones y errores frecuentes **7**

9. Resumen de fórmulas **8**

10. Preguntas de autoevaluación **8**

1. Objetivos de aprendizaje

Al finalizar el material, se espera que el estudiante pueda:

- distinguir métodos deterministas y estocásticos y explicar cuándo puede ser útil el muestreo aleatorio;
- generar muestras reproducibles con NumPy y reconocer distribuciones uniformes, normales y discretas;
- formular una integral como una esperanza matemática y estimarla a partir de muestras;
- interpretar el error estándar y la convergencia típica de Monte Carlo;
- construir simulaciones estocásticas sencillas y analizar caminatas aleatorias;
- contrastar resultados numéricos con predicciones teóricas y comunicar la incertidumbre.

2. ¿Qué es un método Monte Carlo?

Los métodos Monte Carlo utilizan muestras aleatorias para estimar una cantidad de interés. En vez de evaluar una expresión exclusivamente mediante una secuencia fija de operaciones, se simula un conjunto de resultados posibles y se calcula una estadística de la muestra. El nombre alude al azar y a los juegos de casino, pero sus aplicaciones incluyen física estadística, transporte de radiación, difusión, finanzas cuantitativas, optimización y problemas de alta dimensión.

Un método determinista produce el mismo resultado si se ejecuta con los mismos datos y parámetros. Un método Monte Carlo puede producir estimaciones ligeramente distintas entre ejecuciones, porque depende de la muestra. Si se controla la semilla del generador pseudoaleatorio, el experimento computacional se puede reproducir.

2.1. Idea general

1. Definir la cantidad que se desea estimar y el modelo probabilístico.
2. Generar una muestra de acuerdo con la distribución elegida.
3. Calcular una cantidad de interés para cada muestra.
4. Agregar los resultados mediante una media, una proporción u otra estadística.
5. Cuantificar la variabilidad y comprobar la convergencia.

3. Números aleatorios y muestreo

3.1. Números verdaderamente aleatorios y pseudoaleatorios

Un generador de números pseudoaleatorios produce una secuencia mediante un algoritmo determinista. La secuencia está diseñada para imitar propiedades estadísticas del azar. En simulaciones científicas, los generadores modernos suelen ser adecuados, siempre que se seleccionen y utilicen correctamente. No deben confundirse con generadores criptográficos, que persiguen objetivos distintos.

En NumPy se recomienda crear un generador explícito:

```
import numpy as np
rng = np.random.default_rng(2026)  # semilla reproducible
muestra = rng.random(1000)         # uniforme en [0, 1)
```

La semilla fija el estado inicial del generador. Usar la misma semilla, la misma secuencia de llamadas y versiones compatibles permite reproducir el experimento. No es necesario usar siempre la misma semilla; es útil fijarla durante el desarrollo, la docencia y las pruebas.

3.2. Distribuciones comunes

- **Uniforme continua:** $X \sim U(a,b)$. Todos los subintervalos de igual longitud tienen la misma probabilidad. Su densidad es $p(x) = 1/(b-a)$ para $a \le x \le b$.
- **Normal:** $X \sim \mathcal{N}(\mu, \sigma^2)$. Se utiliza para modelar ciertas fluctuaciones y errores, aunque no toda variable física es normal.
- **Bernoulli:** $X \in \{0,1\}$ con $P(X=1) = p$. Modela un ensayo con dos resultados.
- **Discreta general:** se selecciona un resultado entre varios valores con probabilidades asignadas.

La distribución de muestreo debe representar el problema. Generar números uniformes no significa que cualquier variable física resultante sea uniforme: una transformación o un mecanismo de selección puede producir otra distribución.

4. Fundamento estadístico

Sea X una variable aleatoria y $g(X)$ una cantidad calculada a partir de ella. La esperanza de $g(X)$ representa su promedio teórico. Para una muestra independiente $X_1, \ldots, X_N$, el promedio muestral es

$$\overline{g}_N = \frac{1}{N} \sum_{i=1}^{N} g(X_i).$$

Bajo condiciones apropiadas, la ley de los grandes números indica que el promedio muestral converge a la esperanza cuando N aumenta:

$$\overline{g}_N \longrightarrow \mathbb{E}[g(X)].$$

Esto no significa que cada resultado nuevo mejore la estimación ni que el error disminuya monótonamente. La convergencia se entiende estadísticamente.

Si $g(X)$ tiene varianza finita σ_g^2, la varianza de la media muestral es σ_g^2/N, por lo que el error estándar teórico es $\sigma_g/\sqrt{N}$. En la práctica se estima σ_g con la desviación estándar muestral:

$$s_g = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N} (g(X_i) - \overline{g}_N)^2}, \qquad \mathrm{SE}(\overline{g}_N) \approx \frac{s_g}{\sqrt{N}}.$$

Consecuencia práctica: para reducir aproximadamente el error estándar a la mitad se requiere cuadruplicar el tamaño de la muestra. Esto puede hacer que Monte Carlo resulte atractivo en problemas de muchas dimensiones, aunque no siempre sea el método más eficiente para integrales simples.

5. Integración Monte Carlo

5.1. Derivación para una dimensión

Considérese

$$I = \int_a^b f(x)\, dx.$$

Si X tiene distribución uniforme en $[a,b]$, su densidad es $p(x) = 1/(b-a)$. Por definición de esperanza,

$$\mathbb{E}[f(X)] = \int_a^b f(x) p(x)\, dx = \frac{1}{b-a} \int_a^b f(x)\, dx.$$

Despejando la integral se obtiene

$$I = (b-a)\mathbb{E}[f(X)].$$

Al sustituir la esperanza por la media de una muestra independiente $x_1, \ldots, x_N$:

$$\boxed{I_N = \frac{b-a}{N} \sum_{i=1}^{N} f(x_i)}.$$

La fórmula aproxima el área como longitud del intervalo multiplicada por la altura promedio muestreada.

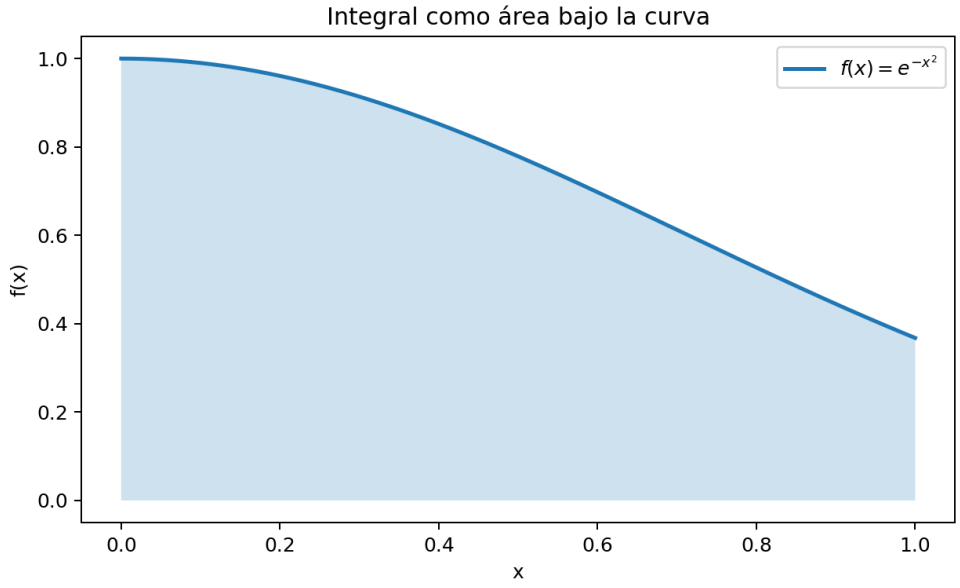


Figura 1: La integral representa el área bajo la curva. Monte Carlo estima la altura media mediante evaluaciones en puntos aleatorios.

5.2. Estimación de la incertidumbre

La desviación estándar de los valores $f(x_i)$ se denota por s_f. La incertidumbre estándar de la estimación de la integral se aproxima por

$$\boxed{\mathrm{SE}(I_N) = \frac{b-a}{\sqrt{N}} s_f.}$$

Esta expresión estima la variabilidad estadística de la media, no todos los posibles errores del modelo o del código. Si las muestras son independientes y la distribución no presenta problemas de varianza infinita, es frecuente interpretar $I_N \pm 2\,\mathrm{SE}$ como un intervalo aproximado de alrededor del 95 % bajo condiciones adicionales habituales. No es una garantía exacta para cualquier muestra o función.

5.3. Ejemplo: integral de e^{-x^2}

Estimar

$$I = \int_0^1 e^{-x^2}\, dx.$$

La integral no tiene una primitiva expresable mediante funciones elementales. Se generan $x_i \sim U(0,1)$ y se calcula $I_N = N^{-1} \sum_i e^{-x_i^2}$. La estimación puede contrastarse con una cuadratura numérica de alta precisión, por ejemplo ‘scipy.integrate.quad‘.

5.4. Estimación de π por área

Considérese el cuadrado unitario $[0,1] \times [0,1]$ y el cuarto de círculo $x^2 + y^2 \leq 1$. El área del cuadrado es 1 y la del cuarto de círculo es $\pi/4$. Si los puntos se distribuyen uniformemente, la probabilidad de caer dentro del cuarto de círculo es

$$p = \frac{\pi}{4}.$$

La proporción observada $\widehat{p} = N_{\text{dentro}}/N$ estima p, así que

$$\boxed{\widehat{\pi} = 4\frac{N_{\text{dentro}}}{N}.}$$

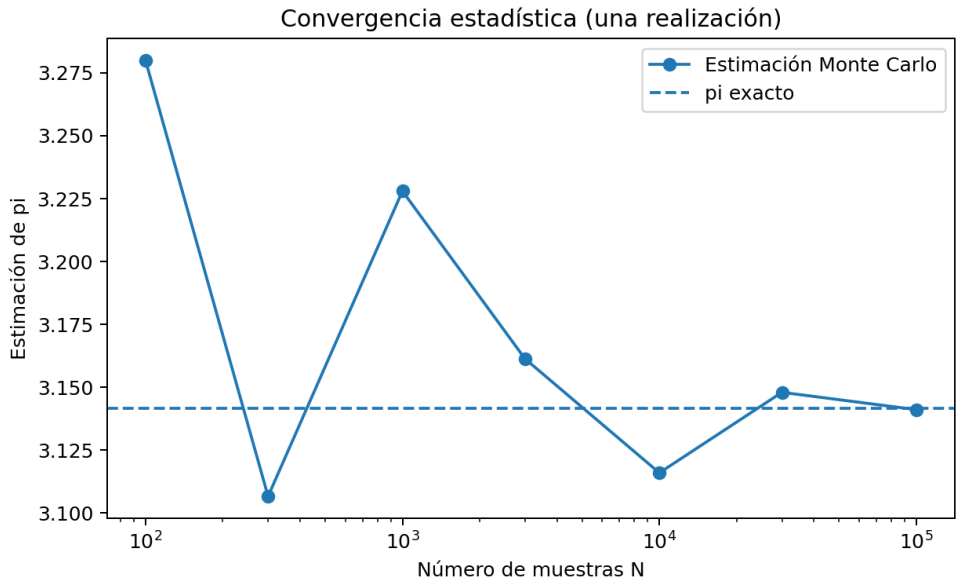


Figura 2: Ejemplo de convergencia de una estimación Monte Carlo. La trayectoria no tiene que acercarse de forma monótona al valor exacto.

La aproximación depende de la muestra; su incertidumbre puede estimarse usando que la variable indicadora es Bernoulli, con varianza $p(1-p)$.

5.5. Integración en varias dimensiones

Para una región rectangular D con volumen V,

$$I = \int_D f(\mathbf{x})\, d\mathbf{x} = V\, \mathbb{E}[f(\mathbf{X})],$$

si $\mathbf{X}$ se distribuye uniformemente en D. Entonces

$$I_N = \frac{V}{N} \sum_{i=1}^{N} f(\mathbf{x}_i).$$

La estimación directa puede ser especialmente útil cuando la dimensión es alta y las cuadraturas deterministas requieren demasiados puntos. Sin embargo, la eficiencia depende de la función, el dominio, la distribución y las técnicas disponibles.

6. Simulación estocástica

Una simulación estocástica describe un sistema cuya evolución incluye variables aleatorias. Se define un estado inicial, se especifican reglas de transición y se repite el experimento para obtener una distribución de resultados.

6.1. Experimento de Bernoulli

En cada ensayo se observa $X_i = 1$ con probabilidad p y $X_i = 0$ con probabilidad $1-p$. El estimador de la probabilidad es

$$\widehat{p} = \frac{1}{N} \sum_{i=1}^{N} X_i.$$

Su esperanza es p y su varianza es $p(1-p)/N$. Por tanto, el error estándar teórico es $\sqrt{p(1-p)/N}$; cuando p es desconocido, se puede reemplazar por $\widehat{p}$ para obtener una estimación.

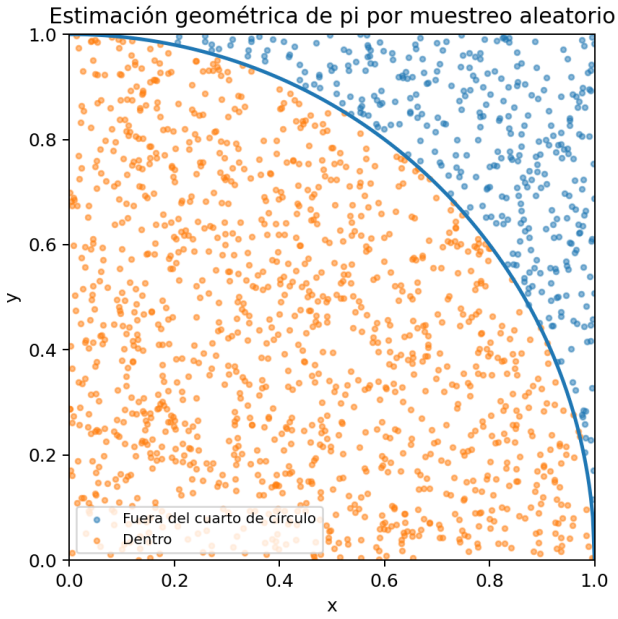


Figura 3: Puntos uniformes dentro y fuera del cuarto de círculo. La proporción dentro aproxima $\pi/4$.

Es normal que una muestra de 10 lanzamientos no produzca exactamente la mitad de caras. La probabilidad teórica no exige que cada muestra finita reproduzca exactamente esa proporción.

6.2. Buenas prácticas

- Separar la definición del modelo, la generación de datos y el análisis de resultados.
- Fijar una semilla para depurar y reproducir ejemplos; documentarla en el informe.
- Usar suficientes realizaciones y distinguir fluctuación aleatoria de errores de programación.
- Comprobar casos simples contra resultados teóricos.
- Etiquetar ejes, unidades y tamaño de muestra en las gráficas.

7. Caminatas aleatorias

7.1. Caminata unidimensional simétrica

Una partícula parte de $x_0 = 0$. En cada paso se mueve $+d$ o $-d$, con probabilidad $1/2$ para cada dirección. Definimos

$$\Delta x_i = \begin{cases} +d, & p = 1/2, \\ -d, & p = 1/2. \end{cases} \qquad x_N = x_0 + \sum_{i=1}^{N} \Delta x_i.$$

Como $\mathbb{E}[\Delta x_i] = 0$, la linealidad de la esperanza implica

$$\mathbb{E}[x_N - x_0] = \sum_{i=1}^{N} \mathbb{E}[\Delta x_i] = 0.$$

Cada paso tiene varianza d^2. Si los pasos son independientes, las varianzas se suman:

$$\mathrm{Var}(x_N - x_0) = N d^2.$$

Dado que la media del desplazamiento es cero,

$$\boxed{\mathbb{E}[(x_N - x_0)^2] = Nd^2}, \qquad \boxed{x_{\text{rms}} = d\sqrt{N}}.$$

El promedio de muchas posiciones finales tiende a cero, pero la dispersión crece como $\sqrt{N}$. No hay contradicción: el promedio y el tamaño típico del desplazamiento son magnitudes distintas.

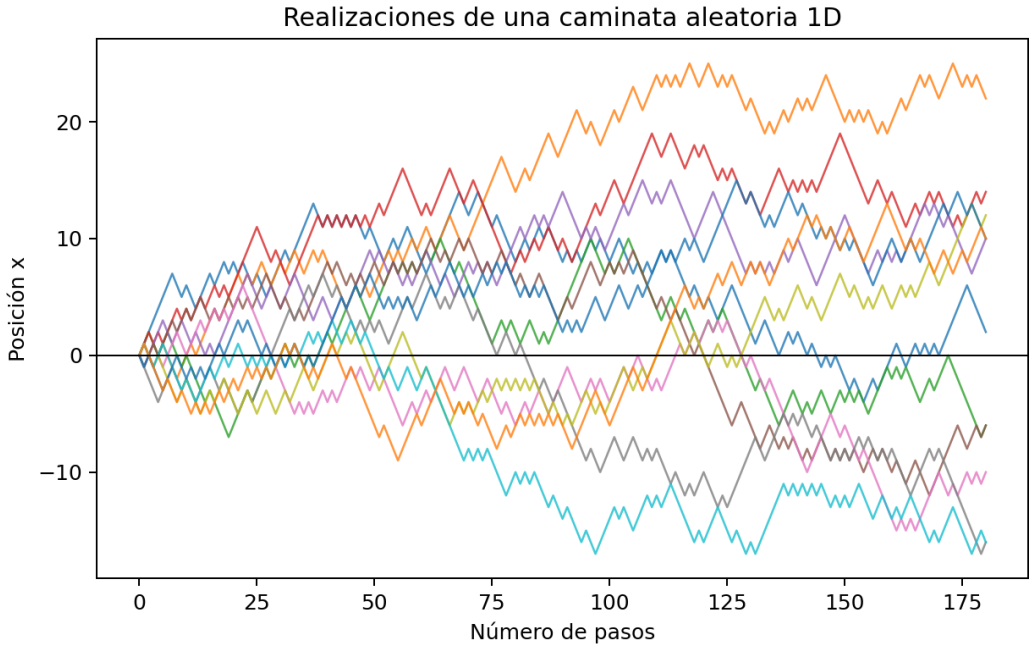


Figura 4: Trayectorias de distintas realizaciones de una caminata aleatoria unidimensional.

7.2. Caminata aleatoria en dos dimensiones

En una cuadrícula, cada paso puede ser hacia arriba, abajo, izquierda o derecha, con probabilidad 1/4 por dirección. Para pasos de longitud d, cada componente tiene media cero y la distancia cuadrática radial esperada después de N pasos es $\mathbb{E}[x_N^2 + y_N^2] = Nd^2$ si cada paso tiene longitud d y las direcciones son independientes y equiprobables. La distribución de posiciones finales se dispersa con el tiempo.

7.3. Conexión con difusión

La caminata aleatoria es un modelo discreto idealizado de procesos difusivos. En una dimensión, para tiempos suficientemente grandes, el desplazamiento cuadrático medio de la difusión cumple $\langle x^2 \rangle = 2Dt$, donde D es el coeficiente de difusión. Si cada paso dura Δt y $\langle x^2 \rangle = Nd^2$ con $t = N\Delta t$, la comparación sugiere $D = d^2/(2\Delta t)$. La relación depende de las hipótesis y de cómo se defina el modelo de pasos.

8. Limitaciones y errores frecuentes

- **Esperar una mejora monótona:** una estimación aleatoria puede empeorar temporalmente aunque aumente N.
- **Confundir error estándar con error absoluto:** el primero estima la variabilidad de la estimación; el segundo requiere conocer un valor de referencia.
- **Usar pocas muestras:** puede generar fluctuaciones grandes, especialmente para eventos raros.

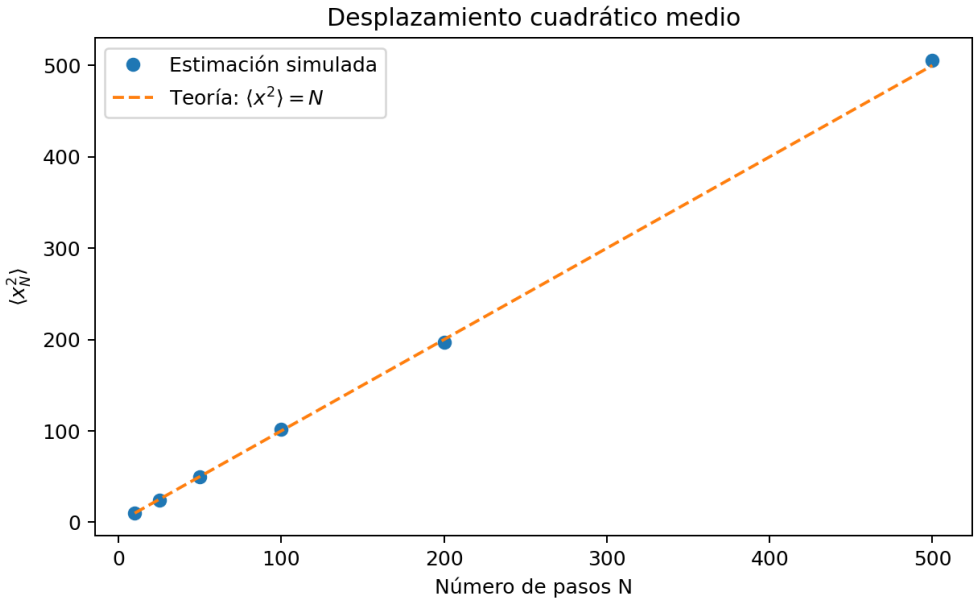


Figura 5: El desplazamiento cuadrático medio crece aproximadamente de forma lineal con el número de pasos.

- **No verificar la distribución:** el método es tan adecuado como lo sea el muestreo elegido.
- **Olvidar la independencia:** las fórmulas básicas de varianza y error estándar dependen de hipótesis sobre las muestras.
- **No comparar con un caso conocido:** una simulación debe validarse siempre que exista una predicción analítica o una solución de referencia.

9. Resumen de fórmulas

Concepto	**Expresión**
Media muestral	$\overline{g}_N = N^{-1} \sum_i g(X_i)$
Error estándar de la media	$s_g/\sqrt{N}$
Integral Monte Carlo en $[a, b]$	$(b-a)N^{-1} \sum_i f(x_i)$
Error estándar de la integral	$(b-a)s_f/\sqrt{N}$
Estimación de π por área	$4N_{\text{dentro}}/N$
Varianza de una caminata simétrica 1D	Nd^2
Desplazamiento cuadrático medio	$d\sqrt{N}$
Difusión en una dimensión	$\langle x^2 \rangle = 2Dt$

10. Preguntas de autoevaluación

1. ¿Por qué conviene fijar una semilla durante el desarrollo de una simulación?
2. ¿Qué diferencia hay entre una probabilidad teórica y una frecuencia observada?
3. ¿Por qué cuadruplicar N reduce aproximadamente a la mitad el error estándar?
4. ¿Cómo se obtiene la fórmula de integración Monte Carlo a partir de la esperanza?
5. ¿Por qué una caminata simétrica puede tener desplazamiento promedio cero y, aun así, alejarse del origen?
6. ¿Qué comparación utilizaría para validar una implementación de Monte Carlo?