Métodos Monte Carlo

Generación aleatoria, integración y simulación estocástica

Computación Avanzada y Analítica

UNIVERSIDAD EIA

Ruta de las dos sesiones

1. Fundamentos y generación de números pseudoaleatorios.
2. Integración Monte Carlo y análisis de incertidumbre.
3. Simulación estocástica.
4. Caminatas aleatorias y conexión con difusión.

Idea central: convertir una cantidad de interés en una estimación estadística basada en muestras.

¿Por qué Monte Carlo?

Método determinista

- Regla fija de cálculo.
- Resultado reproducible para los mismos datos.
- Puede ser muy eficiente en problemas de baja dimensión.

Método Monte Carlo

- Utiliza muestras aleatorias.
- Produce fluctuaciones estadísticas.
- Puede ser atractivo en alta dimensión o modelos complejos.

Receta general

1. Definir la cantidad que se desea estimar.
2. Elegir una distribución que represente el problema.
3. Generar muestras.
4. Calcular una estadística muestral.
5. Cuantificar incertidumbre y validar.

Números pseudoaleatorios en NumPy

```
import numpy as np
rng = np.random.default_rng(2026)
u = rng.random(1000)           # uniforme en [0, 1)
z = rng.normal(0.0, 1.0, 1000) # normal N(0,1)
moneda = rng.binomial(1, 0.5, 1000) # Bernoulli
```

- La semilla permite reproducir la secuencia.
- Una distribución debe elegirse de acuerdo con el modelo.
- Los números generados son pseudoaleatorios, no una fuente criptográfica.

Esperanza y media muestral

$$\mathbb{E}[g(X)] \quad \longleftrightarrow \quad \overline{g}_N = \frac{1}{N}\sum_{i=1}^{N} g(X_i).$$

Ley de los grandes números

Bajo condiciones apropiadas, el promedio muestral converge a la esperanza cuando N aumenta.

La convergencia no implica que cada nueva estimación sea mejor que la anterior.

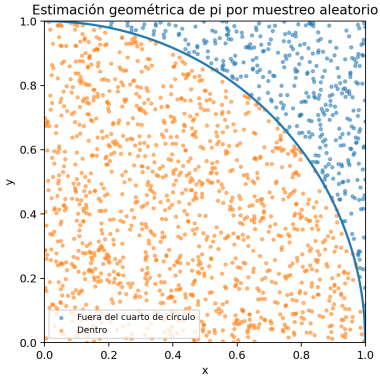
Error estadístico

Si $g(X)$ tiene varianza finita σ_g^2 y las muestras son independientes:

$$\mathrm{SE}(\overline{g}_N) = \frac{\sigma_g}{\sqrt{N}} \approx \frac{s_g}{\sqrt{N}}.$$

- Duplicar N: error típico multiplicado por $1/\sqrt{2}$.
- Cuadruplicar N: error típico aproximadamente a la mitad.
- Es una estimación de variabilidad, no del error absoluto frente a un valor exacto.

Ejemplo 1: estimar π por área



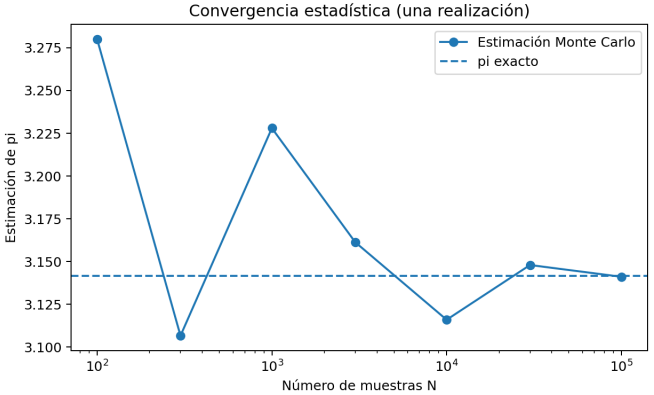
El cuarto de círculo unitario ocupa una fracción $\pi/4$ del cuadrado unitario.

$$\widehat{\pi} = 4\frac{N_{\text{dentro}}}{N}.$$

Contar puntos dentro de $x^2 + y^2 \leq 1$ y dividir por el total.

¿Qué nos enseña la estimación de π?

- El modelo geométrico convierte un área en una probabilidad.
- La proporción observada aproxima la probabilidad teórica.
- La estimación fluctúa de una muestra a otra.
- Es necesario observar el comportamiento para varios tamaños N.



Integración Monte Carlo: derivación

Partimos de $I = \int_a^b f(x)\,dx$. Si $X \sim U(a, b)$, entonces

$$\mathbb{E}[f(X)] = \frac{1}{b-a} \int_a^b f(x)\,dx.$$

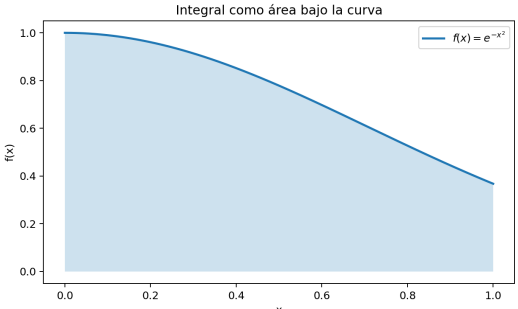
$$\boxed{I = (b-a)\mathbb{E}[f(X)]}$$

Estimador y error de la integral

Para muestras x_i uniformes en $[a, b]$:

$$I_N = \frac{b-a}{N} \sum_{i=1}^{N} f(x_i)$$

$$\mathrm{SE}(I_N) \approx \frac{b-a}{\sqrt{N}} s_f$$



Ejemplo 2: integrar e^{-x^2}

Queremos estimar $I = \int_0^1 e^{-x^2}\, dx$.

```
rng = np.random.default_rng(7)
N = 100_000
x = rng.uniform(0, 1, N)
fx = np.exp(-x**2)
I_mc = np.mean(fx)
SE = np.std(fx, ddof=1) / np.sqrt(N)
```

Discusión: comparar con una cuadratura de SciPy y comprobar si la diferencia es coherente con el error estándar.

Integración en varias dimensiones

Para una región rectangular de volumen V y muestras uniformes X_i:

$$I = \int_D f(\mathrm{x})\, d\mathrm{x} = V\mathbb{E}[f(\mathrm{X})], \qquad I_N = \frac{V}{N}\sum_{i=1}^{N} f(\mathrm{X}_i).$$

Puede ser útil en alta dimensión; la eficiencia depende de la función, la región y el muestreo.

Simulación estocástica

Un modelo estocástico combina:

- estado inicial;
- variables aleatorias;
- reglas de transición;
- observables y estadísticas;
- repetición de realizaciones.

No se interpreta una sola trayectoria como una descripción completa del comportamiento estadístico.

Ejemplo: ensayos de Bernoulli

Para $X_i \in \{0, 1\}$ con $P(X_i = 1) = p$:

$$\widehat{p} = \frac{1}{N} \sum_{i=1}^{N} X_i, \qquad \mathrm{SE}(\widehat{p}) \approx \sqrt{\frac{\widehat{p}(1 - \widehat{p})}{N}}.$$

La frecuencia de una muestra pequeña no tiene por qué ser exactamente p.

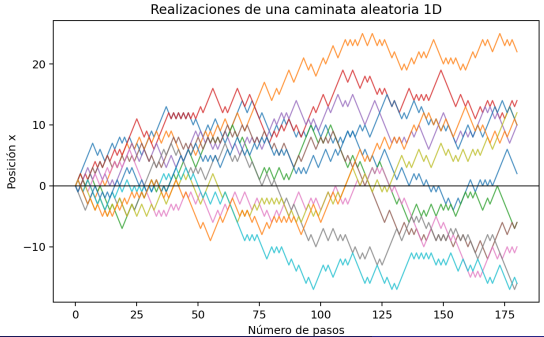
Caminata aleatoria 1D

Cada paso es $+d$ o $-d$ con probabilidad $1/2$.

$$x_N - x_0 = \sum_{i=1}^{N} \Delta x_i.$$

$$\mathbb{E}[x_N - x_0] = 0, \qquad \mathbb{E}[(x_N - x_0)^2] = Nd^2.$$

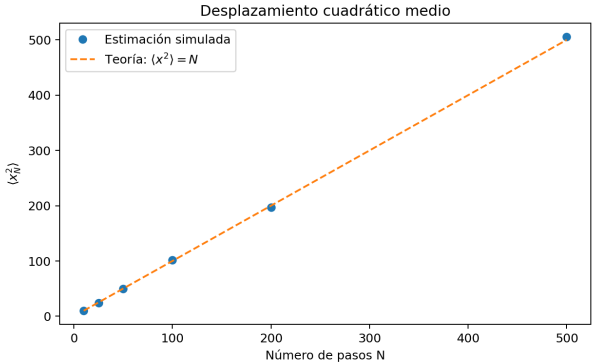
$$x_{\mathrm{rms}} = d\sqrt{N}.$$



Promedio frente a dispersión

El desplazamiento promedio puede ser cero, aunque las partículas se alejen del origen.

- Media: mide el desplazamiento neto promedio.
- Desplazamiento cuadrático medio: mide el tamaño típico del desplazamiento.
- Para pasos independientes, la varianza se suma.



Extensión a 2D y difusión

En una cuadrícula, cada paso puede ir arriba, abajo, izquierda o derecha. Si la longitud del paso es d y las direcciones son equiprobables,

$$\mathbb{E}[x_N^2 + y_N^2] = Nd^2.$$

En difusión unidimensional, $\langle x^2 \rangle = 2Dt$. Si $t = N\Delta t$, se obtiene la relación de escala $D = d^2/(2\Delta t)$ para este modelo idealizado.

Errores frecuentes y buenas prácticas

- Esperar convergencia monótona.
- Confundir error estándar con error absoluto.
- Usar muy pocas muestras para eventos raros.
- No verificar la distribución de muestreo.
- No contrastar con un resultado analítico o determinista.
- No documentar semilla, unidades y tamaño de muestra.

Síntesis y preguntas

Al terminar, debemos poder explicar:

1. cómo se transforma una integral en una esperanza;
2. por qué el error típico decrece como $N^{-1/2}$;
3. cómo validar una simulación aleatoria;
4. por qué el desplazamiento promedio y el cuadrático medio describen cosas diferentes.

Pregunta de cierre: ¿qué ventaja y qué limitación tendría Monte Carlo frente a una cuadratura determinista para el problema que elijan?